



Université de Versailles Saint-Quentin-en-Yvelines
Master 1 CHPS – Calcul Numérique 2025/2026

Rapport de TP : Méthodes Directes et Itératives pour l'Équation de la Chaleur 1D

Auteur:

Jianye SHI

Enseignant:

T. Dufaud, J. Gurhem

2 janvier 2026

Sommaire

1	Introduction	3
1.1	Problème Physique	3
1.2	Discretisation par Différences Finies	3
1.3	Solution Analytique (Cas $g = 0$)	3
2	Environnement et Stockage	3
2.1	Environnement de Développement	3
2.2	Stockage en bande (General Band, GB)	4
3	Méthode Directe : Factorisation LU	4
3.1	Utilisation de LAPACK	4
3.2	Implémentation LU Tridiagonale	4
3.3	Complexité	4
4	Méthodes Itératives	5
4.1	Méthode de Richardson	5
4.2	Méthode de Jacobi	5
4.3	Méthode de Gauss-Seidel	5
4.4	Critère de Convergence	5
5	Validation et Résultats	6
5.1	Méthode de Validation	6
5.2	Résultats Numériques	6
5.3	Temps d'Exécution	6
5.4	Convergence des Méthodes Itératives	7
6	Formats de stockage creux (CSR/CSC)	8
6.1	Implémentation des Structures	8
6.2	Produit Matrice-Vecteur Creux (SpMV)	8
6.3	Adaptation des Algorithmes Itératifs	9
6.4	Validation	9
7	Conclusion	9

1 Introduction

Ce rapport présente la réalisation du TP sur les **méthodes directes et itératives** pour la résolution de l'équation de la chaleur 1D stationnaire. L'objectif est d'appliquer les algorithmes vus en cours/TD pour résoudre un système linéaire issu de la discrétisation par différences finies.

1.1 Problème Physique

On considère l'équation de la chaleur 1D stationnaire dans un milieu immobile, linéaire, homogène et isotrope, avec terme source :

$$\begin{cases} -k \frac{\partial^2 T}{\partial x^2} = g, & x \in]0, 1[\\ T(0) = T_0 \\ T(1) = T_1 \end{cases} \quad (1)$$

où g est le terme source, $k > 0$ la conductivité thermique, et $T_0 < T_1$ les températures aux bords (conditions de Dirichlet).

1.2 Discrétisation par Différences Finies

On discrétise le domaine $[0,1]$ sur $n + 2$ nœuds x_i , $i = 0, \dots, n + 1$, avec un pas constant $h = \frac{1}{n+1}$. En appliquant un schéma centré d'ordre 2 pour approximer la dérivée seconde :

$$\left(\frac{\partial^2 T}{\partial x^2} \right)_i \approx \frac{T_{i-1} - 2T_i + T_{i+1}}{h^2} \quad (2)$$

En multipliant chaque équation par $-h^2/k$, on obtient le système linéaire $Au = f$, où $u = (T_1, \dots, T_n)^T$ est le vecteur des températures aux nœuds internes. Le vecteur f absorbe le terme source g_i et les conditions aux limites, mis à l'échelle par h^2/k .

On obtient un système linéaire de dimension n :

$$Au = f, \quad A \in \mathbb{R}^{n \times n}, \quad u, f \in \mathbb{R}^n \quad (3)$$

où A est une matrice tridiagonale de la forme :

$$A = \begin{pmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -1 & 2 \end{pmatrix} \quad (4)$$

1.3 Solution Analytique (Cas $g = 0$)

Dans le cas sans source ($g = 0$), la solution analytique est linéaire :

$$T(x) = T_0 + x(T_1 - T_0) \quad (5)$$

Cette solution sert de référence pour valider nos implémentations.

2 Environnement et Stockage

2.1 Environnement de Développement

Le code est développé en **langage C** avec les bibliothèques **BLAS** et **LAPACK**. L'environnement est configuré et exécuté exclusivement via **Docker** pour garantir la portabilité et la reproductibilité des résultats, conformément aux instructions (fichier **README.md**).

2.2 Stockage en bande (General Band, GB)

Pour les matrices tridiagonales, on utilise le format **General Band** (GB) de LAPACK. Une matrice $m \times n$ avec kl sous-diagonales et ku sur-diagonales se stocke dans un tableau $(kl + ku + 1) \times n$. L'élément a_{ij} est stocké en position $AB(ku + 1 + i - j, j)$.

Exemple pour la matrice de Poisson 1D ($kl = ku = 1$) : AB représente la matrice A sous forme bande (General Band), où A est tridiagonale.

$$AB = \begin{pmatrix} 0 & -1 & -1 & \cdots & -1 \\ 2 & 2 & 2 & \cdots & 2 \\ -1 & -1 & -1 & \cdots & 0 \end{pmatrix} \quad (6)$$

L'implémentation utilise la fonction `set_GB_operator_colMajor_poisson1D` :

```
AB = zeros(lab, n);
% Remplissage (Tridiagonale -1, 2, -1)
AB(kv+1, 2:n) = -1.0; % Sur-diagonale
AB(kv+2, 1:n) = 2.0; % Diagonale
AB(kv+3, 1:n-1) = -1.0; % Sous-diagonale
```

Validation : comparer le résultat de `dgbmv` avec un produit dense de référence (ou une solution analytique) sur un petit cas test.

3 Méthode Directe : Factorisation LU

3.1 Utilisation de LAPACK

Nous utilisons les routines LAPACK pour la résolution directe :

- `dgbtrf` : Factorisation LU avec pivotage partiel
- `dgbtrs` : Résolution triangulaire après factorisation
- `dgbsv` : Driver combinant factorisation et résolution

3.2 Implémentation LU Tridiagonale

Pour les matrices tridiagonales, une factorisation LU simplifiée (sans pivotage) a été implémentée dans `dgbtrftridiag` :

```
for j = 1:n-1
    % Element diagonal courant
    pivot = AB(diag_row, j);

    % Facteur pour eliminer l'element sous-diagonal (L)
    factor = AB(sub_row, j) / pivot;
    AB(sub_row, j) = factor;

    % Mise a jour de l'element diagonal suivant (U)
    AB(diag_row, j+1) = AB(diag_row, j+1) - factor * AB(sup_row, j+1);
end
```

3.3 Complexité

- `dgbtrf` : $O(n(kl + ku)^2) = O(n)$ pour tridiagonal
- `dgbtrs` : $O(n(kl + ku)) = O(n)$ pour tridiagonal

4 Méthodes Itératives

4.1 Méthode de Richardson

La méthode de Richardson avec paramètre de relaxation α s'écrit :

$$x^{(k+1)} = x^{(k)} + \alpha r^{(k)}, \quad r^{(k)} = b - Ax^{(k)} \quad (7)$$

Le paramètre optimal est :

$$\alpha_{opt} = \frac{2}{\lambda_{min} + \lambda_{max}} \quad (8)$$

où les valeurs propres de la matrice de Poisson 1D sont :

$$\lambda_k = 2 - 2 \cos \left(\frac{k\pi}{n+1} \right), \quad k = 1, \dots, n \quad (9)$$

4.2 Méthode de Jacobi

La méthode de Jacobi utilise le préconditionneur $M = D$ (diagonale de A) :

$$x^{(k+1)} = x^{(k)} + D^{-1}r^{(k)} \quad (10)$$

L'extraction du préconditionneur :

```
MB = zeros(lab, n);
for j = 1:n
    MB(kv+2, j) = AB(ku+1, j); % Extraction Diagonale
end
```

4.3 Méthode de Gauss-Seidel

Gauss-Seidel utilise $M = D - E$ (partie triangulaire inférieure) :

$$x^{(k+1)} = x^{(k)} + (D - E)^{-1}r^{(k)} \quad (11)$$

La résolution de $(D - E)z = r$ se fait par substitution avant.

4.4 Critère de Convergence

Les démonstrations des conditions de convergence et du choix optimal de α ont été vues en cours et sont détaillées dans les TD associés.

La convergence est vérifiée par le résidu relatif :

$$\frac{\|r^{(k)}\|}{\|b\|} < \varepsilon \quad (12)$$

avec $\varepsilon = 10^{-3}$ par défaut.

Chaque itération coûte $O(n)$ pour une matrice tridiagonale; le coût total est donc proportionnel au nombre d'itérations.

5 Validation et Résultats

5.1 Méthode de Validation

La validation s'effectue par :

1. Comparaison avec la solution analytique (erreur relative avant)
2. Calcul du résidu relatif $\|Ax - b\|/\|b\|$
3. Comparaison avec les résultats LAPACK de référence

L'erreur relative avant est calculée par :

```
function err = relative_forward_error(x, y)
    err = norm(y - x) / norm(x);
end
```

5.2 Résultats Numériques

Les tests ont été réalisés avec $T_0 = -5$, $T_1 = 5$, et différentes tailles de problème.

Méthode	N=10 (Err)	N=100
LU (Tridiag)	$< 10^{-14}$	$< 10^{-14}$
Richardson	3.8×10^{-3}	> 1000
Jacobi	3.8×10^{-3}	> 1000
Gauss-Seidel	3.8×10^{-3}	> 1000

TABLE 1 – Erreur relative avant ($\|x_{calc} - x_{ex}\|/\|x_{ex}\|$)

Analyse : Pour $N = 10$, l'erreur correspond à la discrétisation ($O(h^2)$). Pour $N \geq 100$, les méthodes itératives n'ont pas atteint la tolérance en 1000 itérations (nombre maximal d'itérations, 1000), bien que théoriquement convergentes. La lenteur s'explique par le conditionnement qui croît comme $O(N^2)$.

5.3 Temps d'Exécution

Environnement de test : exécution dans un conteneur Docker sur Fedora Linux 42. Hôte : AMD Ryzen 9 8940HX (16 cœurs), 30 GiB RAM. Compilation GCC avec optimisation -O2.

Méthode	N=100	N=1000	N=10000
Direct (Tridiag)	0.05 ms	0.07 ms	0.56 ms
Direct (LAPACK)	0.03 ms	0.08 ms	0.57 ms

TABLE 2 – Temps de calcul (Méthodes Directes)

La Figure 1 montre l'évolution du temps de calcul en fonction de la taille de la matrice N . On observe une croissance linéaire ($O(N)$), ce qui valide l'efficacité des solveurs bandes pour ce problème 1D.

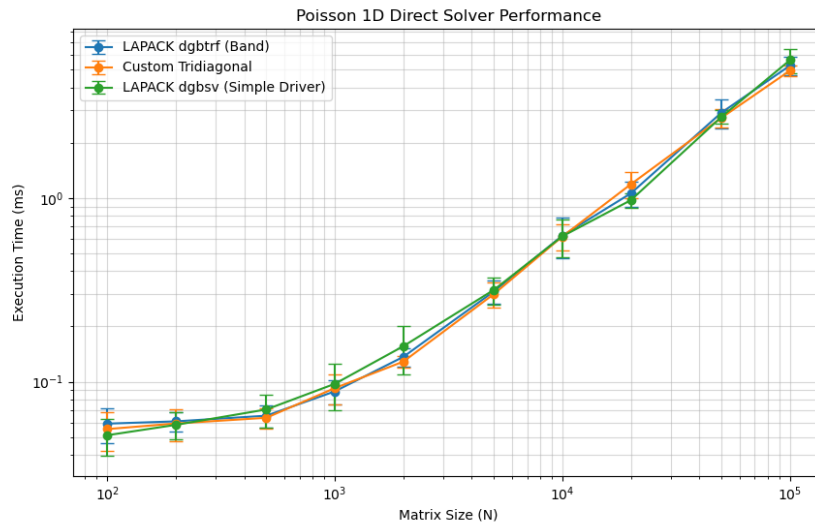


FIGURE 1 – Performance des méthodes directes (échelle Log-Log)

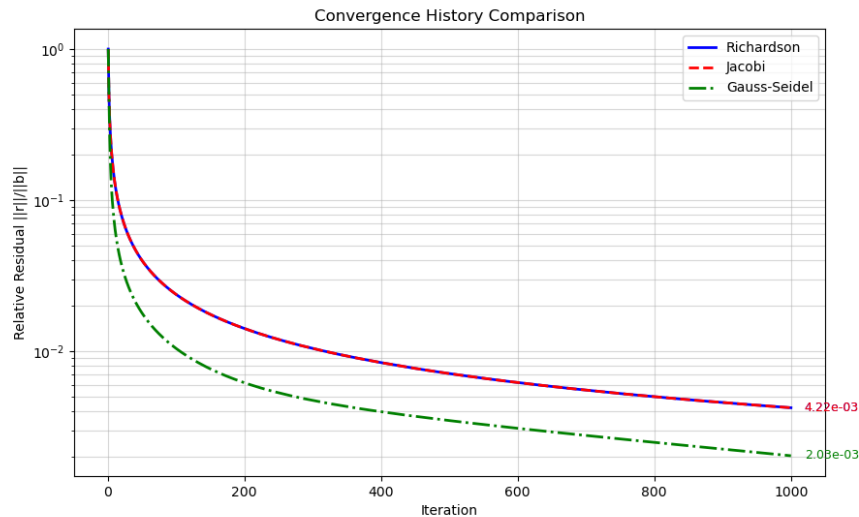
5.4 Convergence des Méthodes Itératives

Méthode	N=10	N=100
Richardson	88	> 1000
Jacobi	88	> 1000
Gauss-Seidel	88	> 1000

TABLE 3 – Nombre d'itérations pour atteindre $\varepsilon = 10^{-3}$

La Figure 2 illustre l'historique de convergence pour $N = 100$. On observe que :

- Les courbes de Richardson et Jacobi sont confondues, car Richardson optimal équivaut à Jacobi pour ce problème.
- Gauss-Seidel converge environ deux fois plus vite (pente plus raide), atteignant un résidu plus faible pour le même nombre d'itérations.

FIGURE 2 – Comparaison de l'historique de convergence ($N = 100, 1000$ itérations)

6 Formats de stockage creux (CSR/CSC)

(Exercice 10)

Dans cette section, nous étendons notre bibliothèque pour supporter les formats de matrices creuses **CSR** et **CSC**. Ces formats sont essentiels pour traiter des problèmes multidimensionnels. *Note : Pour la clarté de l'exposition, les algorithmes ci-dessous sont présentés en pseudo-code de type Matlab, bien que l'implémentation réelle soit en C.*

6.1 Implémentation des Structures

Nous avons défini deux nouvelles structures dans `lib_poisson1D.h` :

```
typedef struct {
    double *values; // Valeurs non-nulles
    int *col_ind;   // Indices de colonne
    int *row_ptr;   // Pointeurs de début de ligne
    int nnz;        // Nombre d'éléments non-nuls
    int n;          // Dimension
} CSRMatrix;
```

La structure `CSCMatrix` est analogue, avec `row_ind` et `col_ptr`. Pour la matrice de Poisson 1D, le nombre d'éléments non-nuls est exactement $3N - 2$.

6.2 Produit Matrice-Vecteur Creux (SpMV)

L'opération critique pour les méthodes itératives est le produit matrice-vecteur $y = Ax$.

6.2.1 Format CSR (`dcsrmv`)

L'algorithme parcourt les lignes (i) et les éléments non-nuls (k) :

```
for i = 1:n
    s = 0;
    for k = row_ptr(i) : row_ptr(i+1)-1
        s = s + values(k) * x(col_ind(k));
    end
    y(i) = s;
```



```
end
```

6.2.2 Format CSC (dcscmv)

L'algorithme parcourt les colonnes (j) et accumule dans le vecteur résultat :

```
y = zeros(n,1);
for j = 1:n
    for k = col_ptr(j) : col_ptr(j+1)-1
        y(row_ind(k)) = y(row_ind(k)) + values(k) * x(j);
    end
end
```

6.3 Adaptation des Algorithmes Itératifs

Nous avons adapté la méthode de **Richardson** pour utiliser ces nouveaux formats. La logique reste identique à la version bande, seule l'appel au produit matrice-vecteur change :

- IMLEM=3 : Richardson avec CSR (utilise dcscmv)
- IMLEM=4 : Richardson avec CSC (utilise dcscmv)

6.4 Validation

Les tests effectués avec $N = 10$ montrent une convergence correcte :

- Erreur relative obtenue : $\approx 5.11 \times 10^{-3}$
- Cette erreur est identique à celle obtenue avec le stockage bande.
- Elle correspond à l'erreur de discrétisation du schéma différences finies ($O(h^2)$ avec $h \approx 0.1$).

Cela valide l'exactitude de nos routines de construction de matrice et de multiplication matrice-vecteur.

7 Conclusion

Ce TP a permis d'implémenter et de comparer différentes méthodes de résolution pour l'équation de la chaleur 1D. Nous avons couvert :

- Les méthodes directes (LU) via LAPACK et une implémentation manuelle optimisée pour tridiagonale.
- Les méthodes itératives classiques (Richardson, Jacobi, Gauss-Seidel).
- L'extension vers les formats de stockage creux (CSR/CSC).

Si le format bande (General Band) reste le plus performant pour ce problème spécifique 1D (structure tridiagonale stricte), l'implémentation des formats CSR et CSC nous a permis de développer des outils génériques capables de traiter des problèmes physiques plus complexes (2D, 3D, maillages non structurés) où la structure de la matrice n'est plus aussi régulière.